



UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação
Departamento de Ciências de Computação

Métodos para previsão de utilidade de comentários sobre produtos para a língua portuguesa

Henrique Garcia Gomes do Ó

Orientador: Thiago Alexandre Salgueiro Pardo

Monografia referente ao projeto de conclusão de curso dentro do escopo da disciplina SCC-0293 do Departamento de Ciências de Computação (SCC) do Instituto de Ciências Matemáticas e de Computação – ICMC-USP para obtenção do título de Bacharel em Ciências de Computação.

Área de Concentração: Inteligência Computacional

USP – São Carlos
04/06/2026

Dedicatória

Este trabalho é dedicado à memória de minha mãe, pelo seu suporte incondicional e suas contribuições inestimáveis para meu crescimento. Entristeço-me por não ter tido a oportunidade de ver-me formado.

Agradecimentos

Agradeço com todo coração a orientação atenciosa do professor Thiago Pardo. Suas direções e contribuições foram o que me deram a perseverança necessária ao longo da realização deste trabalho.

Também agradeço o meu pai, que ajudou a corrigir erros ortográficos e facilitar a legibilidade estrutural do texto.

Resumo

A predição de utilidade de resenhas consiste em determinar automaticamente quais comentários de usuários fornecem análises relevantes para potenciais consumidores. Essa tarefa é particularmente importante em ambientes de comércio eletrônico, onde resenhas são relevantes para estabelecer a intenção de compra. Neste trabalho, investigam-se métodos para predição de utilidade de resenhas em português brasileiro utilizando a base de dados *SteamBR*, composta por avaliações de jogos digitais. Foram desenvolvidas e comparadas duas abordagens distintas: um método simbólico baseado em métricas textuais relacionadas a tamanho, legibilidade, intensidade emocional e características do produto, e um método sub-simbólico baseado no ajuste fino do modelo *BERTimbau*. Após etapas de filtragem, pré-processamento e avaliação experimental, os resultados indicaram superioridade da abordagem sub-simbólica baseada em *Transformers*, que obteve *F1-score* de 86,51%, em comparação ao de 79,91% alcançado pelo método simbólico. A análise qualitativa demonstrou que o modelo sub-simbólico apresenta maior capacidade de generalização, enquanto o método simbólico oferece maior interpretabilidade. Os resultados contribuem para o estudo da predição de utilidade de resenhas em português e evidenciam os benefícios de métodos neurais modernos para essa tarefa.

Índice

LISTA DE ABREVIATURAS/SIGLAS	VI
LISTA DE TABELAS	VII
LISTA DE ALGORITMOS	VIII
LISTA DE FIGURAS	IX
CAPÍTULO 1: INTRODUÇÃO	1
1.1. CONTEXTUALIZAÇÃO E MOTIVAÇÃO	1
1.2. OBJETIVOS	2
1.3. ORGANIZAÇÃO DO TRABALHO	3
CAPÍTULO 2: REVISÃO BIBLIOGRÁFICA	4
2.1. CONSIDERAÇÕES INICIAIS	4
2.2. CONCEITOS E TÉCNICAS RELEVANTES	4
2.2.1. <i>CORPUS</i> , LÉXICOS E PRÉ-PROCESSAMENTO	4
2.2.2. ABORDAGENS	6
2.3. A TAREFA DE PREDIÇÃO DE UTILIDADE DE RESENHAS	9
2.4. CONSIDERAÇÕES FINAIS	10
CAPÍTULO 3: DESENVOLVIMENTO DO TRABALHO	11
3.1. CONSIDERAÇÕES INICIAIS	11
3.2. DESCRIÇÃO DO PROJETO	11
3.2.1. A BASE DE DADOS STEAMBR	11
3.2.2. PIPELINE DA SOLUÇÃO SIMBÓLICA	12
3.2.3. PIPELINE DA SOLUÇÃO SUB-SIMBÓLICA	15
3.3. DESCRIÇÃO DAS ATIVIDADES REALIZADAS	16
3.3.1. PRÉ-PROCESSAMENTO COMUM AOS DOIS MÉTODOS	16

3.3.2. EXTRAÇÃO DE MÉTRICAS E CLASSIFICAÇÃO NO MÉTODO SIMBÓLICO	17
3.3.2.1. NÚMERO DE TOKENS (NUM_TOK)	17
3.3.2.2. NÚMERO DE SENTENÇAS (NUM_SET)	18
3.3.2.3 TAMANHO MÉDIO DE FRASES (ASL)	18
3.3.2.4 INTENSIDADE SENTIMENTAL (SENT_INT)	18
3.3.2.5 NOTA SMOG (SMOG_GRADE)	19
3.3.2.6 ATRIBUTOS DO PRODUTO (PROD_FEAT)	20
3.3.3. AJUSTE FINO DO BERTIMBAU	20
3.3.3.1 BALANCEAMENTO DE DADOS	21
3.3.3.2 TOKENIZAÇÃO	21
3.3.3.3 APRENDIZAGEM PROFUNDA	21
3.3.3.4 CAMADAS ADICIONAIS PARA CLASSIFICAÇÃO	22
3.4. RESULTADOS OBTIDOS	22
3.4.1 ANÁLISE QUANTITATIVA	22
3.4.2 ANÁLISE QUALITATIVA	26
3.5. DIFICULDADES E LIMITAÇÕES	27
3.6. CONSIDERAÇÕES FINAIS	28
CAPÍTULO 4: CONCLUSÃO	29
4.1. CONTRIBUIÇÕES	29
4.2. RELACIONAMENTO ENTRE O CURSO E O PROJETO	29
4.3. CONSIDERAÇÕES SOBRE O CURSO DE GRADUAÇÃO	29
4.4. TRABALHOS FUTUROS	30
REFERÊNCIAS	32

Lista de Abreviaturas/Siglas

- *BERT: Bidirectional Encoder Representation for Transformers*
- *GBM: Gradient Boosting Machine* (do inglês, Máquina de Aumento de Gradiente)
- *PLN: Processamento de Linguagem*¹ Natural
- *LLM: Large Language Model* (do inglês, Grande Modelo de Língua)
- *SMOG: Simplified Measure of Gobbledygook*

¹ O termo "linguagem" foi imprecisamente traduzido do inglês, uma vez que o PLN analisa um aspecto específico da linguagem: a língua. Ainda assim, optou-se por utilizar o termo conforme é empregado de praxe na literatura.

Lista de Tabelas

Tabela 1 - Exemplos de Resenhas Útil e Não Útil.....	2
Tabela 2 - Atributos Relevantes do SteamBR.....	12
Tabela 3 - Métricas para Avaliação dos Métodos.....	23
Tabela 4 - Matrizes de Confusão dos Métodos.....	23

Lista de Algoritmos

Algoritmo 1 - Algoritmo de predição de utilidade de resenha.....	13
--	----

Lista de Figuras

Figura 1 - Pipeline do Método Simbólico.....	13
Figura 2 - Pipeline do Método Sub-simbólico.....	15
Figura 3 - Concordância em Erros dos Modelos.....	24
Figura 4 - Concordância em Falsos Positivos.....	25
Figura 5 - Concordância em Falsos Negativos.....	25

CAPÍTULO 1: INTRODUÇÃO

1.1. Contextualização e Motivação

O Processamento de Linguagem Natural (PLN) é o campo de estudo que permite aos computadores interpretar e gerar linguagem natural. Com a popularização dos modelos neurais mais recentes, como os *Transformers* (VASWANI et al., 2017), a área ganhou grande ênfase no mercado de trabalho e como objeto de estudo, sobretudo com a aplicação de grandes modelos de língua (*LLMs - Large Language Models*, no inglês) para tarefas variadas, como tradução automática, sumarização de textos, análise de sentimentos e suas vertentes e a classificação de textos (ZHAO et al., 2023). Esta última tarefa pode ser usada para predição de utilidade de comentários na web, sendo portanto de interesse a este trabalho.

A popularização do comércio digital trouxe consigo uma ampla disponibilidade de informações sobre os produtos anunciados na forma de resenhas geradas pelos compradores. Como constatado em (ISMAGILOVA et al., 2020), a presença de resenhas detalhadas e úteis é valorizada por usuários para estabelecer a intenção de compra. É importante, portanto, que *sites* de comércio eletrônico priorizem apresentar as resenhas mais úteis para um comprador em potencial.

Grandes sites de comércio eletrônico, como Mercado Livre e Amazon, permitem que comentários sejam avaliados por usuários para determinar o quão útil eles foram, no entanto, essa solução é suscetível ao viés dos adotantes iniciais (*early bird bias*), ou seja, resenhas mais antigas tendem a acumular mais votos positivos por estarem disponíveis há mais tempo na plataforma. No domínio de jogos digitais, por exemplo, esse viés pode distorcer a impressão sobre um jogo, uma vez que prioriza a opinião de pessoas que compraram o jogo cedo. Observações próprias do autor do presente trabalho indicam que problemas que só existiam nas primeiras versões de um jogo podem ser exacerbados, ou fãs enviesados que já estavam esperando o lançamento podem exagerar pontos positivos do jogo.

1.2. Objetivos

Com o intuito de permitir aos sistemas avaliar quais comentários devem ser mostrados para melhor informar o consumidor em potencial, independentemente do número de votos positivos acumulados pela resenha, este projeto investiga métodos automáticos para determinar a utilidade destes comentários, com foco em português brasileiro, em prol de atender a escassez relativa de pesquisas desta área nesta língua.

As abordagens investigadas incluem tanto métodos clássicos (simbólicos) da Inteligência Artificial quanto métodos mais recentes (baseados em redes neurais). Eles, ultimamente, devem ser capazes de expressar se um comentário é útil ou não a partir do seu texto.

Como dados de referência, prevê-se utilizar a base de dados SteamBR (JORGE; PARDO, 2023), construída com comentários de usuários sobre jogos digitais, um domínio de grande interesse dos jovens. Como ilustração, a Tabela 1 demonstra um exemplo de uma resenha considerada útil e de outra não útil nesta base.

Tabela 1 - Exemplos de resenhas consideradas Útil e Não Útil

Comentário Útil	<i>“Foi um game excelente mas atualmente 21/12/17 , o número de cheaters está absurdo. Praticamente impossível de jogar. A cada 10 partidas pelo menos 8 você esbarra com um hacker. Infelizmente se a BlueHole não tomar alguma atitude , esse game vai ser tomado pelos hackers. Deixo minha recomendação negativa enquanto não for feito algo sobre isso. Me parte o coração mas desse jeito não dá...”</i>
Comentário não Útil	<i>“É meio ruim mas é bom, a jogabilidade é meio ruim, mas é boa, os gráficos são meio feios, mas são bonitos.”</i>

Fonte: elaboração do autor (2026).

O comentário útil demonstra uma opinião sincera que aponta um problema claro e objetivo no jogo, auxiliando então um comprador em potencial a entender o que esperar dele.

Enquanto isso, o segundo comentário é vago e contraditório. Provavelmente trata-se de uma piada. Ele não tem valor de informar um comprador em potencial.

Para o desenvolvimento do trabalho, além da revisão literária, faz-se necessário principalmente realizar o pré-processamento dos dados (cujas tarefas dependem das especificidades dos métodos), projetar e implementar algoritmos de classificação dos comentários e avaliar as soluções produzidas, indicando limitações e potencialidades. Essas etapas são exploradas neste trabalho de conclusão de curso, utilizando-se conceitos e técnicas aprendidos no curso de graduação.

1.3. Organização do Trabalho

No Capítulo 2, é apresentada uma explicação sucinta dos conceitos básicos que fundamentam o trabalho, assim como alguns artigos que constituem a literatura relevante para as tarefas realizadas. Em seguida, no Capítulo 3, são descritas as atividades realizadas bem como são avaliados e comparados os resultados. Por último, no Capítulo 4, discute-se brevemente como o curso apoiou o desenvolvimento do projeto e finalmente propõem-se trabalhos futuros.

CAPÍTULO 2: REVISÃO BIBLIOGRÁFICA

2.1. Considerações Iniciais

Este capítulo apresenta os conceitos básicos e trabalhos relacionados que fundamentam o desenvolvimento deste trabalho. Inicialmente, são discutidos conceitos relevantes de PLN. Em seguida, são apresentados trabalhos relacionados à predição de utilidade de resenhas e às ferramentas utilizadas neste estudo.

2.2. Conceitos e Técnicas Relevantes

Esta seção apresenta os principais conceitos, recursos e técnicas de PLN utilizados ao longo deste trabalho.

2.2.1. *Corpus*, Léxicos e Pré-Processamento

Em PLN, dados costumam ser a base do desenvolvimento e avaliação de aplicações. Em especial, com a popularização das técnicas de aprendizado de máquina na Inteligência Artificial, os dados têm grande destaque na área. Os dados textuais utilizados, anotados ou não com informações relevantes para a tarefa de interesse, constituem o que se chama de *corpus* em PLN. Apesar de não ser mais usual distinguir os conceitos de *corpus* e *datasets*, definições clássicas de *corpus* indicam que estes devem ser construídos de maneira que atendam critérios de propósito de uso e de qualidade do material utilizado, devendo ser representativos dos fenômenos de interesse, entre outros critérios (SARDINHA, 2000).

Muitas vezes é necessário pré-processar os dados do *corpus*, realizando tarefas como tokenização, sentencição e normalização textual. A tokenização é usualmente o primeiro passo para a análise textual em PLN, consistindo na divisão dos blocos de texto em fragmentos processáveis. Estes são os *tokens*. O que é considerado um *token* varia conforme a aplicação. Por exemplo, a entrada “Inesquecível.” pode ser tokenizada por

caracteres [“I”, “n”, “e”, “s”, “q”, “u”, “e”, “c”, “i”, “v”, “e”, “l”, “.”], por palavras [“Inesquecível”, “.”] ou, como de praxe nas aplicações modernas que utilizam abordagens neurais, por subpalavras [“In”, “esquec”, “ível” “.”].

A representação de *tokens* como subpalavras atende a alguns problemas relevantes na construção de um vocabulário tokenizado. Ao separar palavras em partes, podemos, por exemplo, aprender palavras novas ao quebrá-las em partes conhecidas. Tal abordagem reduz o tamanho dos vocabulários e permite a inferências de significados de partículas por modelos. No exemplo dado, um modelo pode inferir que o prefixo “in-” implica negação quando observar palavras como “infeliz”, “interminável” e “inadequado” e, a partir daí, entender que “inesquecível” significa “não esquecível”. Em especial, deve-se apontar que a tokenização em subpalavras é interessante para línguas como o português, dotadas de muitas conjugações verbais e palavras derivadas.

Em algumas aplicações, é relevante normalizar o texto, isto é, padronizar sua representação antes do processamento. Procedimentos comuns incluem a expansão de abreviaturas (“oq” torna-se “o quê”), a correção ortográfica (“voce” torna-se “você”), a adequação do uso de letras maiúsculas e minúsculas e a substituição de determinadas entidades por tokens representativos. Por exemplo, a expressão “60 FPS” pode ser transformada em “[número] fps”. Também é comum converter todo o texto para minúsculas. Essas técnicas têm como objetivo reduzir o tamanho do vocabulário, aumentar a eficiência do processamento e diminuir ruídos introduzidos por variações de escrita ou erros humanos. Entretanto, esse processo implica perda de informação, o que pode torná-lo inadequado para determinadas tarefas em que tais distinções carregam significado relevante.

Para muitas tarefas, recursos léxicais são muito importantes, pois organizam os dados sobre as palavras da língua de interesse. Há léxicos de língua geral, léxicos especializados e também aqueles que categorizam as palavras de acordo com critérios variados. Destacamos aqui o léxico LIWC, de especial interesse para este trabalho. O *LIWC* (no inglês, *Linguistic Inquiry and Word Count*) organiza as palavras e subpalavras em uma ou mais categorias de acordo com função textual, processo cognitivo, informalidade, emoções, entre outras. Ele é especialmente útil como ferramenta na tarefa

de análise de sentimentos. Há várias versões desse léxico para o português. Aqui utilizaremos a de (CARVALHO et al., 2024).

2.2.2. Abordagens

A Inteligência Artificial e o PLN têm trajetórias com diferentes abordagens. Inicialmente, métodos simbólicos foram predominantes na área, manipulando explicitamente símbolos (palavras e outros elementos textuais). Essas abordagens foram seguidas por métodos estatísticos, que buscavam, em sua maioria, aprender padrões probabilísticos dos dados de interesse. Na última década, métodos neurais se destacaram, em especial, aqueles ditos profundos (no inglês, *deep learning*). Apesar desse trajeto e suas transições predominantes serem claramente visíveis na área de PLN, nenhuma abordagem foi totalmente descartada, sendo que há uma tendência para abordagens híbridas. Detalham-se a seguir as abordagens utilizadas neste trabalho de conclusão de curso.

Métodos simbólicos adotam uma solução inteligível baseada em inferências lógicas bem estabelecidas. Eles têm a vantagem da explicabilidade de seus resultados, ou seja, uma vez que conhecemos as regras, um humano pode facilmente compreender que características do texto influenciaram no resultado. Por exemplo, considere um modelo simbólico que valoriza textos pelos seguintes parâmetros: número de caracteres, adequação à norma padrão da língua portuguesa e intensidade emocional. Pode-se entender facilmente porque uma entrada como “*é só pra um personagem*” pode ser penalizada pelo modelo.

Apesar de suas vantagens, em PLN estes métodos são expressivamente menos robustos em comparação aos métodos mais recentes, uma vez que não lidam bem com ruído e inferências além das pré-estabelecidas.

Os métodos sub-simbólicos, que incluem os estatísticos e neurais, não utilizam regras, lógica e outras representações linguísticas explícitas. Eles inferem padrões através do aprendizado baseado nos dados inseridos, muitas vezes filiando-se à linha de aprendizado de máquina.

Métodos probabilísticos são abordagens matemáticas e computacionais que utilizam a teoria da probabilidade para modelar e analisar fenômenos incertos. Eles

representam o conhecimento através de distribuições probabilísticas e estimam a chance de eventos futuros. Em PLN, técnicas como Redes Bayesianas, Cadeias de Markov, Modelos Ocultos de Markov e classificadores Naive-Bayes permitem modelar a incerteza inerente à linguagem humana por meio de distribuições de probabilidade. Essas abordagens foram amplamente utilizadas em tarefas como classificação de textos e tradução de máquina, especialmente antes da popularização dos modelos baseados em redes neurais profundas.

Métodos baseados em redes neurais artificiais são soluções bioinspiradas cuja arquitetura é separada em camadas interconectadas de neurônios artificiais (que, na realidade, são elementos que computam funções matemáticas) com capacidade de processamento de dados. Até agora, os métodos citados necessitavam da seleção manual de características relevantes (*feature engineering*); no entanto, redes neurais artificiais permitem romper com essa necessidade, já que podem selecionar automaticamente que características analisar. Elas tendem a apresentar resultados melhores que métodos tradicionais de aprendizado de máquina, no entanto, também necessitam de um número comparativamente grande de dados para seu treinamento e apresentam menor explicabilidade quanto aos resultados. Entre os métodos que se enquadram nesse paradigma estão os perceptrons multicamadas (*MLP*), as redes neurais convolucionais (*CNN*), as redes neurais recorrentes (*RNN*) e os modelos baseados em *Transformers*, sobre os quais é interessante comentar mais, dada sua relevância atual.

Transformers são arquiteturas de redes neurais introduzidas por (VASWANI et al., 2017), baseadas no mecanismo de atenção. Diferentemente das arquiteturas recorrentes, os *Transformers* contêm camadas de atenção na rede neural que permitem processar tokens em paralelo e capturar relações contextuais entre termos distantes no texto. As características da arquitetura trouxeram dois grandes avanços na área: o paralelismo em treinamento de modelos, o que tornou o processo mais eficiente, e a captura de dependências de longa distância.

Em essência, neste panorama, a influência de um *token* na tarefa de interesse é ajustada em relação a outros do texto. Cria-se portanto uma série de vantagens, como melhor compreensão (computacional) do conteúdo textual e modelagem de dependências de longa distância. Por exemplo, a palavra “banco” pode se referir a uma instituição bancária, um tipo de assento ou um repositório de algum material (banco de areia, por

exemplo). Humanos entendem intuitivamente que na frase “Sentei no banco.”, a palavra adota o segundo significado; no entanto, métodos computacionais clássicos tinham dificuldade em realizar tal distinção. Agora, uma vez que definimos o *token* pela sua relação com outros, fica possível diferenciar palavras polissemânticas pelo seu contexto.

Transformers são divididos em duas partes: o *Encoder* e o *Decoder*. O *Encoder* aplica transformações sobre as sequências de entrada, resultando em representações vetoriais (*embeddings*) contextualizadas de cada *token*. O *Decoder* utiliza o contexto derivado dos vetores para gerar uma sequência de saída. Os famosos modelos de língua se servem dessas etapas para realizarem suas tarefas. Na maior parte das vezes, utilizam apenas a parte de *Decoder*, mas há casos que usam as duas partes e também aquelas que utilizam apenas o *Encoder*. Em especial, o *BERT* (*Bidirectional Encoder Representation for Transformers*) (DEVLIN et al., 2019) é um caso de modelo baseado no *Encoder*. Ele difere da maioria dos modelos linguísticos de sua época ao explorar o contexto de um *token* em ambas as direções (os que vêm antes e depois da palavra) ao invés de somente uma. Esta característica permite uma sofisticação maior ao determinar o contexto de cada *token*. Este modelo foi pré-treinado com imensas quantidades de dados textuais; no entanto, a maioria destes está em inglês. Em resposta, foi desenvolvido o BERTimbau (SOUZA et al., 2020), um modelo *BERT* especificamente treinado para o português brasileiro, sendo provavelmente a variante mais famosa disponível para essa língua.

O BERTimbau utilizou o *brWAc* (BOOS et al., 2014) como *corpus* para seu treinamento. O modelo foi treinado em dois tamanhos distintos: o *Base*, que conta com 12 camadas, dimensão oculta de 768 unidades, 12 cabeças de atenção e 110 milhões de parâmetros, e o *Large*, que conta com 24 camadas, dimensão oculta de 1024 unidades, 16 cabeças de atenção e 330 milhões de parâmetros. O *brWAc* (*Brazilian Web As Corpus*) é uma coleta automática de páginas da rede (*webcrawl*) que conta com 2,68 bilhões de *tokens* extraídos de 3,53 milhões de documentos, resultando em 17,5 GB de texto processado em português brasileiro, abrangendo domínios variados.

2.3. A Tarefa de Predição de Utilidade de Resenhas

A predição de utilidade de resenhas pode ser modelada como uma tarefa de classificação binária de comentários de usuários com classes “útil” e “não útil”. Tradicionalmente, a literatura utiliza a proporção entre avaliações positivas e o total de avaliações de utilidade para determinar o rótulo de referência de uma resenha. Na ausência de avaliações negativas, como é o caso em lojas como a *Steam*, determina-se a classe verdadeira através de um limiar aplicado sobre o número normalizado de votos positivos (os *likes*, normalmente) de uma resenha. Se o número estiver acima deste limiar, a resenha é considerada “útil”, caso contrário, é considerada “não útil”.

Destacam-se aqui dois artigos para o português que foram essenciais para este trabalho de conclusão de curso. O primeiro introduz a base de dados utilizada e o segundo apresenta conceitos e atributos que se mostraram importantes para diversas definições.

Em (JORGE; PARDO, 2023), é apresentada a base de dados SteamBR. Ela contém 2.777.509² resenhas de jogos digitais identificadas como escritas em português, separadas por gênero. Um método sub-simbólico de predição de utilidade utilizado no artigo obteve um *f1-score* de 0,9. O algoritmo utilizado para isso foi o *Gradient Boosting Machine* (GBM). O artigo foi inspirado em (BAOWALY et al., 2019), que usou um método similar para analisar a utilidade de resenhas em inglês de jogos na mesma loja digital, obtendo ao final um *f1-score* de 0,94.

Em (SOUSA; PARDO, 2021), é calculado o quanto características textuais individuais afetam a utilidade (*helpfulness*) de uma resenha. Este artigo foi instrumental para decidir que características considerar para o método simbólico deste trabalho. Vale apontar que o trabalho utiliza a base de dados *UTLcorpus*, introduzida em (SOUSA et al., 2019). Ela contém resenhas em português e abrange domínios distintos: filmes e aplicativos. Acredita-se que, dada sua natureza variada da base, o conhecimento obtido a partir dela possa ser transferido para o domínio de jogos digitais.

² O artigo reporta 2.789.893 resenhas, enquanto a leitura do conjunto de dados retornou 2.777.509 registros. Utilizou-se o valor obtido experimentalmente neste trabalho. A origem da discrepância é desconhecida.

2.4. Considerações Finais

Por questões de interesse pessoal do autor, assim como a praticidade de se avaliar um domínio somente, optou-se por utilizar a base de dados *SteamBR* ao invés da *UTLcorpus* para este estudo.

Com o objetivo de analisar a evolução dos métodos de PLN, decidiu-se testar uma abordagem simbólica e também utilizar uma arquitetura baseada em *Transformers* como método sub-simbólico. Como este trabalho pretende unicamente classificar resenhas como “útil” ou “não útil”, e não gerar saída textual, foi escolhido um modelo *Encoder-only* para realizar o trabalho. Para atender o objetivo de ampliar a literatura do estudo de PLN na língua portuguesa, o BERTimbau foi o modelo de escolha.

O desenvolvimento do trabalho é relatado na próxima seção.

CAPÍTULO 3: DESENVOLVIMENTO DO TRABALHO

3.1. Considerações Iniciais

Em acordo com a literatura, adotou-se um método simbólico como base de comparação do método sub-simbólico baseado em *Transformers*.

Os métodos avaliam unicamente o texto das resenhas, sem considerar portanto os metadados (como autoria, localização do usuário e histórico de publicações, por exemplo). Esta decisão foi tomada para criar uma solução baseada somente no processamento do conteúdo textual.

Este capítulo tem o objetivo de prover uma explicação detalhada da base de dados utilizada, da arquitetura dos métodos escolhidos e da implementação destes, atentando-se à motivação por trás das escolhas feitas. Por fim, são apresentados e analisados os resultados obtidos.

3.2. Descrição do Projeto

Nesta seção, é apresentada uma visão geral da solução proposta antes da descrição detalhada de sua implementação.

3.2.1. A Base de Dados *SteamBR*

O *SteamBR* é uma base de dados coletada por varredura na loja Steam. Os atributos relevantes para o trabalho, assim como uma explicação breve do que consistem, se encontram na Tabela 2.

Tabela 2 - Atributos Relevantes do *SteamBR*

Atributo	Descrição
<i>review</i>	O texto da resenha.
<i>votes_up</i>	Número de votos acumulados de avaliação positiva.
<i>weighted_vote_score</i>	Número normalizado de votos, ponderado quanto a gênero.
<i>language</i>	Língua à qual a resenha foi atribuída.

Fonte: elaboração do autor (2026).


Uma análise manual feita sobre as resenhas incluídas na base de dados encontrou algumas características de nota:

- Há o emprego de muitos jargões em inglês ligados a jogos digitais. Exemplos incluem *multiplayer*, *FPS*, *RPG*, *skilltree*, entre outros;
- Comentários utilizam expressões vulgares para criar ênfase. Um exemplo é a entrada: “*Um jogo bom pra caralho, na minha opinião melhor dentre os 3. [...]*”;
- Apesar da língua de todas as resenhas estarem sinalizadas como “*brazilian*”, percebe-se que, verdadeiramente, há resenhas em inglês no meio de uma maioria em português brasileiro;
- A base de dados não registra votos negativos. Dessa forma, não é possível distinguir comentários amplamente aceitos daqueles que receberam tanto avaliações positivas quanto negativas, o que dificulta a análise de sua controvérsia;
- A maioria esmagadora dos comentários tem zero avaliações positivas.

3.2.2. Pipeline da solução simbólica

A proposta de método simbólico segue o *pipeline* de processos exibidos na Figura 1. Este método adota uma solução inteligível para determinar se uma resenha é útil. Para tal, foram extraídas certas métricas do texto da resenha, elas foram normalizadas e foram aplicados pesos sobre elas para chegar a uma nota final que categorize cada resenha como “útil” ou “não útil”.

Figura 1 - Pipeline do Método Simbólico



Fonte: elaboração do autor (2026).

O algoritmo 1 descreve passo a passo como classificar uma resenha. O pré-processamento abrange os passos 1 a 3, a extração de métricas abrange os passos 4 a 15, o cálculo da nota final abrange os passos 16 e 17 e a classificação abrange os passos 18 e 19. Os pesos foram escolhidos com base em (SOUSA; PARDO, 2021), priorizando as características textuais que mostraram uma maior correlação positiva com a utilidade da resenha. Foi decidido não incluir erros de ortografia como uma das métricas, dado que o domínio tem caráter informal e portanto adota bastantes gírias, abreviações, variações de escrita, e termos estrangeiros que seriam tidos como erros ortográficos. Adicionalmente, uma resenha pode ser útil para um potencial consumidor independentemente de expressar sentimentos positivos ou negativos. Por esse motivo, optou-se por considerar apenas a intensidade do sentimento expresso, e não sua polaridade.

Métodos simbólicos costumam incluir um passo de normalização do texto, uma vez que são sensíveis a ruído. Ainda assim, uma análise preliminar com uma amostra da base de dados (10.000 entradas) apresentou uma diferença pequena no *f1-score* resultante da normalização. Portanto, tomou-se a decisão de omitir este passo do algoritmo.

Algoritmo 1 - Algoritmo de predição de utilidade de resenha

- Entrada: resenha em português a classificar
- Saída: classe “útil” ou “inútil”
- 1. Checar se a resenha de entrada está apropriada (tamanho, língua, etc)
- 2. Se não estiver, classifique como inútil ou interrompa o sistema
- 3. Tokenizar o texto
- 4. Contabilizar número de tokens (num_tok)
- 5. Contabilizar número de sentenças (num_set)


6. $asl = num_tok / num_set$
7. $SENT_int = 0$
8. Para cada palavra da frase, faça consulta ao LIWC
 - a. Se a categoria da palavra for positiva ou negativa, some 1 a $SENT_int$
 - b. Senão, prossiga
9. $SENT_int = SENT_int / num_tok$
10. Contabilize o número de palavras polissilábicas (número de sílabas ≥ 3)
11. Utilize o número de palavras polissilábicas e número de sentenças para calcular a nota SMOG da frase ($SMOG_grade$)
12. $prod_feat = 0$
13. Para cada palavra da frase, consulte o dicionário de atributos do produto.
 - a. Se houver correspondência, adicione 1 a $prod_feat$
14. $prod_feat = prod_feat / num_tok$.
15. Normalize as métricas num_tok , num_set , asl , $SENT_int$, $SMOG_grade$, $prod_feat$
16. Assuma os seguintes pesos para cada característica a ser avaliada
 - a. Peso 1 ($p1$) para tamanho médio de sentença normalizado (asl) = 0,3
 - b. Peso 2 ($p2$) para número de tokens normalizado (num_tok) = 0,1
 - c. Peso 3 ($p3$) para número de sentenças normalizado (num_set) = 0,1
 - d. Peso 4 ($p4$) para intensidade do sentimento normalizada ($SENT_int$) = 0,3
 - e. Peso 5 ($p5$) para nota de legibilidade SMOG normalizada ($smog_grade$) = 0,1
 - f. Peso 6 ($p6$) para número de características de produto normalizado ($prod_feat$) = 0,1
17. Para a review em avaliação, faça

$$nota\ da\ resenha = p1 * asl + p2 * num_tok + p3 * num_set + p4 * SENT_int + p5 * smog_grade + p6 * prod_feat$$
18. Se a nota da resenha for > 0.5 , então classifique-a como “útil”
19. Senão, classifique-a como “não útil”

3.2.3. Pipeline da solução sub-simbólica

O *pipeline* de processos da solução sub-simbólica, baseada no BERTimbau, é exibido na Figura 2.

Figura 2 - Pipeline do Método Sub-simbólico



Fonte: elaboração do autor (2026).

Este método abrange uma solução típica de modelos baseados em *Transformers* para classificação. Em essência, recebe-se o texto bruto, tokeniza-se o texto e transforma os *tokens* em representações vetoriais, tipicamente de alta dimensionalidade. Para essa transformação inicial, consideram-se os vetores associados aos *tokens* em si (obtidos no pré-treinamento do modelo), a posição de cada token na sentença e a que segmento do texto eles pertencem. Depois, as representações vetoriais, também chamadas de *embeddings*, são transformadas pelas camadas do modelo. Com o mecanismo de atenção da arquitetura, as representações adquirem contextualidade.

Essas arquiteturas empregam um vetor adicional específico para classificação (referenciado pela sigla *CLS*), que é um token especial colocado no início da sentença que carrega a representação agregada desta. Toma-se o *CLS* da última camada da arquitetura e nulifica-se aleatoriamente o valor de alguns componentes do vetor em uma camada adicional chamada de *Dropout*. Este processo é feito a fim de evitar o *over-fitting* do modelo, o que poderia diminuir sua capacidade de generalização. Depois disso, o resultado

é inserido em mais uma camada adicional, que faz uma transformação linear, reduzindo a dimensionalidade do vetor para o número de classes desejadas. No caso, são duas classes. Os valores obtidos por esta transformação são chamados de *logits*. Em seguida, aplica-se a função matemática *softmax* sobre estes *logits* para transformá-los em probabilidades (números de 0 a 1 cuja soma é 1). A classificação, neste ponto, baseia-se em escolher a classe cuja probabilidade relacionada é a maior.

3.3. Descrição das Atividades Realizadas

A seguir, são descritas as etapas de implementação dos métodos investigados neste trabalho. São apresentados o pré-processamento dos dados, a extração das métricas utilizadas pelo método simbólico e o processo de ajuste fino do modelo sub-simbólico.

3.3.1 Pré-processamento Comum aos Dois Métodos

Em acordo com (JORGE; PARDO, 2023), somente comentários com 3 ou mais votos positivos foram utilizados. Essa decisão foi feita tanto para garantir performance aos modelos utilizados quanto para deixar o resultado comparável com o artigo citado previamente. Restaram 233.993 resenhas depois da transformação.

Para garantir a integridade da base de dados, utilizou-se a biblioteca *Python langdetect*³ para identificar e remover as resenhas que não estavam em português. Este passo removeu 31.077 resenhas, mantendo um volume suficiente de dados para aplicar os métodos propostos. Deve-se notar que houve falsos negativos associados a esta análise automática, especialmente quando a resenha era muito pequena (uma ou duas palavras). Expressões que vêm do inglês, mas são utilizadas corriqueiramente no Brasil, como “top”, também deixaram comentários menores suscetíveis a remoção.

O dataset foi dividido aleatoriamente em três conjuntos: validação (10% das instâncias), treinamento (70% das instâncias) e teste (20% das instâncias). Para fins de verificação, consideramos como valor de referência que uma resenha pertence a categoria

³ Biblioteca disponível em: <https://pypi.org/project/langdetect/>

“útil” se ela tem o número de votos ponderado maior que 0,5. Caso contrário, ela pertence à categoria “não útil”.

3.3.2 Extração de Métricas e Classificação no Método Simbólico

As resenhas foram tokenizadas utilizando a biblioteca *Python spacy*⁴. Para evitar que apenas poucos valores extremos (*outliers*) recebessem pontuação máxima em determinadas métricas, foram utilizados métodos de normalização não lineares. Na maioria das métricas, utilizou-se o terceiro quartil (Q3) do valor da métrica no conjunto de validação como valor considerado suficientemente grande. Dessa forma, textos com valores acima do percentil 75 recebem pontuação máxima, reduzindo a influência de valores excessivamente altos.

As métricas utilizadas são descritas sucintamente nas subseções a seguir.

3.3.2.1 Número de Tokens (num_tok)

O número de *tokens* em um texto. Sua normalização foi definida pela função:

$$\min\left(\frac{n_{tok}}{Q3_{n_{tok}}}, 1\right), \text{ onde:}$$

- n_{tok} representa o número de *tokens* do texto;
- $Q3_{n_{tok}}$ representa o terceiro quartil da distribuição do número de *tokens* no conjunto de validação.

⁴ Biblioteca disponível em: <https://pypi.org/project/spacy/>

3.3.2.2 Número de Sentenças (num_set)

O número de sentenças em um texto. Esta métrica foi obtida utilizando uma função da biblioteca Spacy. Sua normalização foi definida pela função: $\min(\frac{n_{set}}{Q3_{n_{set}}}, 1)$, onde:

- n_{set} representa o número de sentenças do texto;
- $Q3_{n_{set}}$ representa o terceiro quartil da distribuição do número de sentenças no conjunto de validação.

3.3.2.3 Tamanho Médio de Frases (asl)

O tamanho médio de frases em um texto. Esta métrica foi obtida pela função $\frac{n_t}{n_{set}}$. Sua normalização foi definida pela função: $\min(\frac{asl}{Q3_{asl}}, 1)$, onde:

- asl representa o tamanho médio das frases do texto;
- $Q3_{asl}$ representa o terceiro quartil da distribuição do tamanho médio de frases no conjunto de validação.

3.3.2.4 Intensidade Sentimental (SENT_int)

A densidade da intensidade emocional contida em um texto. O dicionário *LIWC* (*Linguistic Inquiry and Word Count*) 2015 da língua portuguesa foi utilizado para realizar essa tarefa. As categorias mais relevantes para este trabalho são as relacionadas à super categoria emoção (*affect*). Para contabilizar a intensidade emocional do texto, a quantidade de palavras pertencentes às categorias emoção positiva (*pos_emo*) ou emoção negativa

(*neg_emo*) utilizando o dicionário como referência. Sua normalização foi definida pela função: $\min(\frac{d_{int}}{Q3_{SENT_{int}}}, 1)$, onde:

- d_{int} representa a densidade da intensidade emocional;
- $Q3_{SENT_{int}}$ representa o terceiro quartil da distribuição da densidade da intensidade emocional no conjunto de validação.

3.3.2.5 Nota **SMOG** (*smog_grade*)

É uma nota de legibilidade do texto. O *Simplified Measure of Gobbledygook* (*SMOG*), introduzido em (McLAUGHLIN, 1969), estima quantos anos de educação são necessários para compreender um texto, com base na sua quantidade de palavras polissilábicas (definidas como contendo 3 ou mais sílabas). Há certas preocupações ao utilizar esta métrica, uma vez que ela foi feita para textos em inglês (palavras com 3 ou mais sílabas são mais comuns em português) o que pode deturpar a métrica. Também, a métrica foi feita para textos com 30 ou mais frases, o que não vai ser verdade para a maioria das resenhas. No entanto, como ela mostrou uma boa correlação com a utilidade do comentário em (SOUSA; PARDO, 2021), foi decidido incluí-la.

A contagem de sílabas foi feita utilizando um dicionário de hifenização *Hunspell* para língua portuguesa brasileira⁵, através da biblioteca *Python pyphen*⁶. O dicionário associa cada palavra com uma versão hifenizada dela, onde cada sílaba é separada por pelo sinal de pontuação.

Sua normalização assume que um texto com nível de escolaridade do fim do colegial (de acordo com o padrão de educação americano, este seria 12 anos) é suficientemente bom para saturação completa. Esta foi definida pela função:

$$\min(\frac{SMOG}{12}, 1).$$

⁵ Dicionário disponível em: <https://github.com/woorm/dictionaries/tree/main/dictionaries/pt>

⁶ Biblioteca disponível em: <https://pypi.org/project/pyphen/>

3.3.2.6 Atributos do Produto (prod_feat)

A quantidade de características do produto encontrada na resenha. Utilizou-se um dicionário preenchido por termos selecionados do conjunto de validação para determinar o que conta como característica de produto. O dicionário consiste em termos como *FPS*, *glitch* e *singleplayer*. Sua normalização foi definida pela função: $\min(\frac{n_{feat}}{Q3_{n_{feat}}}, 1)$, onde:

- n_{feat} é o número de característica de produtos contidas em uma resenha;
- $Q3_{n_{feat}}$ representa o terceiro quartil da distribuição do número de característica de produtos em resenhas no conjunto de validação.

Para determinar a nota final, utilizou-se a seguinte fórmula para cada resenha:

$$nota\ da\ resenha = 0,3 * asl + 0,1 * num_tok + 0,1 * num_set + 0,3 * SENT_int + 0,1 * smog_grade + 0,1 * prod_feat$$

Os pesos, como citado anteriormente, foram escolhidos com base no artigo (SOUSA; PARDO, 2021), de forma a priorizar as métricas que demonstraram maior correlação com a nota da resenha.

Para classificar a resenha como não útil ou útil, utilizou-se o limiar 0,5, o mesmo para estabelecer o valor de referência. Se a nota final for maior que 0,5, ela é prevista útil, caso contrário, ela é prevista inútil. Esse limiar foi escolhido para manter a comparabilidade com (JORGE; PARDO, 2023), que utilizou o mesmo.

3.3.3 Ajuste fino do BERTimbau

Com eficiência em mente, foi decidido utilizar o modelo *Bertimbau Base* para prever a categoria final de uma resenha. Foi realizado um ajuste fino no modelo para melhor adequá-lo à tarefa.

3.3.3.1 Balanceamento de Dados

Dentre os três conjuntos que compõem a base de dados filtrada, 187.730 resenhas foram classificadas por referência como útil e 15.221 foram classificadas por referência como não útil. Em outras palavras, somente 7,5% dos valores são considerados não úteis. Mesmo que este fator não apresente um problema no método simbólico, que é baseado em regras rígidas, testes revelaram que, no caso dos modelos sub-simbólicos baseados em aprendizado de máquina, o desbalanceamento das classes acaba levando os modelos à tendência de prever a classe dominante na grande maioria das vezes. Consequentemente, o número de falsos negativos na predição da classe minoritária foi muito grande em relação ao número de ocorrências verdadeiras da mesma. Para remediar tal problema, foi empregado o balanceamento de dados na forma da subamostragem da classe majoritária (*undersampling*) unicamente no conjunto de treinamento. Assim, garantiu-se que ambas as classes tenham representação igualitária neste conjunto, resultando em 10.598 instâncias para cada uma.

3.3.3.2 Tokenização

O tokenizador utilizado foi o *BertTokenizer*, padrão do *BERT* e baseado em subpalavras. Utilizou-se do truncamento de sequências com mais de 128 tokens, de modo a adequá-las aos requisitos de entrada do modelo e reduzir o custo computacional.

3.3.3.3 Aprendizagem Profunda

Para o ajuste fino, a avaliação do modelo foi realizada utilizando a métrica *F1-score*, escolhida por sua capacidade de equilibrar precisão (*precision*) e revocação (*recall*), sendo especialmente adequada para cenários com possível desbalanceamento entre classes. Durante o treinamento, o modelo foi otimizado com taxa de aprendizado de 0,00002, utilizando tamanho de lote (*batch size*) de 16 para treino e 64 para validação, ao longo de 3 épocas. Foi aplicado *weight decay* de 0,01 como forma de regularização, além de uma fase de *warmup* com 1.000 passos para estabilização inicial do treinamento. Estes

hiperparâmetros foram escolhidos com o tamanho do modelo em busca de conciliar eficiência computacional com robustez do modelo.

O desempenho do modelo foi monitorado ao final de cada época, sendo selecionado como modelo final aquele que apresentou o melhor valor de *F1-score* no conjunto de validação.

3.3.3.4 Camadas Adicionais para Classificação

O *CLS* da última das 12 camadas do *BERTimbau*, com 768 dimensões, é enviado para a camada de *Dropout*. Esta, assim como padrão da arquitetura *BERT*, apresenta uma taxa de 0,1, ou seja, 10% dos valores do vetor serão esquecidos (nulificados).

Após a transformação linear, obtém-se os *logits*. Por fim, na etapa de inferência, as probabilidades são obtidas a partir dos *logits* por meio da função *Softmax*, sendo a classe com maior probabilidade selecionada como a predição final do modelo.

3.4. Resultados Obtidos

Os resultados obtidos pelos métodos são apresentados e discutidos nesta seção. A análise é conduzida sob duas perspectivas: quantitativa, por meio das métricas de avaliação, e qualitativa, com base na inspeção dos erros de classificação.

3.4.1 Análise Quantitativa

A Tabela 3 apresenta as métricas obtidas pelos métodos simbólico e sub-simbólico analisados. A Tabela 4 apresenta suas matrizes de confusão.

Tabela 3 - Métricas para Avaliação dos Métodos

Método	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	F1
Simbólico	67,42%	92,95%	70,08%	79,91%
Sub-simbólico	77,43%	96,66%	78,28%	86,51%

Fonte: elaboração do autor (2026).

Tabela 4 - Matrizes de Confusão dos Métodos


Método	TN	FP	FN	TP
Simbólico	1.081	1.995	11.226	26.289
Sub-simbólico	2.062	1.014	8.147	29.368

Fonte: elaboração do autor (2026).

Observa-se que o modelo sub-simbólico superou o simbólico em todas as métricas. Uma análise por *bootstrap* com 10.000 reamostragens revelou que a diferença entre seus *f1-scores* é estatisticamente significativa.

A concordância quanto aos erros de classificação entre os métodos é apresentada na Figura 3. Em geral, os métodos produziram a mesma predição em 63,98% dos casos. Considerando apenas as instâncias em que pelo menos um dos métodos cometeu erro, ambos erraram simultaneamente em 20,97% dos casos. Observa-se ainda que o método simbólico apresentou 9.340 erros exclusivos, enquanto o método sub-simbólico apresentou 5.280, o que corresponde a 76,89% mais erros exclusivos para o método simbólico.

Figura 3 - Concordância em Erros dos Modelos




Fonte: elaboração do autor (2026).

As Figuras 4 e 5 demonstram, respectivamente, a concordância em falsos positivos e falsos negativos. Percebe-se que cerca de 33,18% dos falsos positivos do simbólico são compartilhados. Em contrapartida, cerca de 65,28% dos falsos positivos do sub-simbólico são compartilhados. Isso sugere que existe um conjunto de exemplos intrinsecamente difíceis, que levam ambos os métodos a produzir falsos positivos. Entretanto, o método simbólico gera um número expressivamente maior de falsos positivos exclusivos, indicando menor capacidade de distinguir corretamente exemplos negativos.


A análise dos falsos negativos evidencia a principal vantagem da abordagem sub-simbólica. Apenas 3.219 falsos negativos são compartilhados entre os métodos, enquanto 8.007 ocorrem exclusivamente no método simbólico. Isso demonstra que a abordagem sub-simbólica consegue recuperar uma parcela expressiva dos exemplos positivos perdidos pelo método simbólico, justificando o aumento observado no *recall*.

Figura 4 - Concordância em Falsos Positivos



Fonte: elaboração do autor (2026).

Figura 5 - Concordância em Falsos Negativos



Fonte: elaboração do autor (2026).

3.4.2 Análise Qualitativa

Esta seção oferece uma discussão de caráter subjetivo sobre as falhas dos métodos, visando oferecer uma análise qualitativa dos dados que possam subsidiar melhorias futuras. Uma análise dos erros que os modelos cometeram demonstrou que:

- Os textos que geraram falsos positivos no método simbólico tendem a ser maiores. A média do número de tokens de resenhas que geraram falsos positivos exclusivamente na classificação do método simbólico é 108,56, enquanto a mesma métrica para o método sub-simbólico é 13,40. Isto se dá pois o método simbólico valoriza explicitamente o tamanho do texto. O modelo BERTimbau treinado valorizou, em geral, textos com uma diversidade maior de tamanho. É possível que isso possa mudar se a janela de contexto do modelo sub-simbólico fosse maior (256 tokens ao invés de 128, por exemplo).
- Os textos pequenos que geraram positivos no método simbólico têm intensidade emocional grande. Textos como *“jogabilidade meio ruim , grafico feio , nao recomendo”* ou *“DLC muito mal feito, com vários mecânicas que se contradizem e acabam prejudicando o jogo.”* demonstram que o modelo tem uma tendência de valorizar textos pouco informativos desde que sejam pequenos e emocionalmente intensos.
- Os falsos positivos exclusivos ao modelo sub-simbólico foram gerados principalmente a partir de textos pequenos que, em geral, expressam opiniões sem fundamentos. Exemplos são: *“Lega O Game recomendo!”*, *“muito bom eu recomenda\n”* e *“melhor jogo de 2021”*. No entanto, vale apontar que os verdadeiros positivos exclusivos deste método também incluem uma grande quantidade de comentários assim. Conclui-se que parte da superioridade métrica do modelo se deu, em parte, justamente pela postura mais branda quanto a que tipo de texto é considerado útil.
- Há algumas resenhas bem estruturadas e informativas que foram preditas úteis por ambos os modelos, mas a classificação não condiz com o valor de referência. Assume-se que estas são uma decorrência de vieses humanos com os quais os modelos não foram capazes de lidar. Um fragmento de um exemplo é: *“[...] Arida compensa os gráficos não muito impressionantes com uma arte conceitual*

belíssima. A trilha sonora também não desaponta e - assim como a arte - possui boa sintonia com o jogo. [...] Vale muito a pena o preço e com certeza estabelece bem o clima para o próximo título.”

- Os falsos negativos gerados exclusivamente pelo método sub-simbólico são formados, em geral, de textos maiores. Isso não implica, no entanto, que o modelo penaliza resenhas grandes. A média do número de tokens de resenhas que foram consideradas úteis pelo modelo (143,78) foi maior do que a média da base de teste em geral (129,38). Isto, portanto, indica que o tamanho da resenha não é um bom indicador para prever a resposta do modelo treinado.
- Os falsos negativos exclusivos ao método simbólico são muito similares aos falsos positivos exclusivos ao modelo sub-simbólico. Isso reforça a ideia de que a diferença fundamental entre os modelos é que o sub-simbólico é mais propenso a considerar uma resenha como útil.
- Os falsos negativos comuns aos dois métodos são, mais uma vez, textos em geral pequenos que expressam opiniões sem fundamentos. É incerto o que os difere dos textos que o método sub-simbólico considerou útil.

3.5. Dificuldades e Limitações

O que espera-se de uma resenha útil é uma opinião informada e persuasiva. No entanto, percebemos que, pelo menos no domínio de jogos, piadas e apelos puramente emocionais - sendo esses elogios e xingamentos sem explicações - recebem votos positivos também. A definição dos valores de referência se demonstrou insuficiente para fazer distinções mais elaboradas. O modelo sub-simbólico acabou, consequentemente, aprendendo que este tipo de comentário é útil, quando pode-se argumentar que ele é incapaz de propriamente informar um comprador em potencial.

Adicionalmente, como foi avaliado somente o texto das resenhas, os métodos não são capazes de lidar com certos vieses que somente os metadados revelariam. Por exemplo, é intuitivo que jogos mais populares possuirão mais visibilidade e portanto mais votos em seus comentários (*popularity bias*). Similarmente, resenhas mais distantes da data de coleta da base de dados têm mais chance de serem vistas e receberem votos (*early bird bias*).

Finalmente, entende-se que o maior empecilho para uma análise qualitativa dos resultados é a natureza caixa-preta do modelo sub-simbólico. Como métodos de aprendizado profundo perdem interpretabilidade quando comparados aos mais clássicos, uma análise do processo é complexo e pouco transparente.

3.6. Considerações Finais

Perante a tudo discutido, podemos observar que o método simbólico se provou mais limitado. Percebemos claramente que os textos valorizados tendem a dois grupos: longos e curtos enquanto emocionais. Em um nível operacional, a explicabilidade do método seria um problema em potencial. Uma vez que seja possível inferir que certas características em um comentário deixam ele mais visível, pessoas com intenção de manipular a percepção de um produto podem escrever resenhas que propositalmente apelam para o modelo com intuito de ganhar mais visibilidade. Em lojas de comércio eletrônico onde qualquer um pode vender seu produto, essa estratégia poderia ser usada para aumentar vendas.

Conclui-se, portanto, que o método sub-simbólico seria o mais adequado dentre os dois para uma aplicação real. Além de apresentar um desempenho melhor na tarefa de classificação, a dificuldade de interpretação de suas decisões, um obstáculo para a análise científica, curiosamente torna-se uma vantagem relevante. Além disso, um método baseado em redes neurais permite a possibilidade de alterar os pesos do modelo à medida que dados se tornam disponíveis, assim possibilitando a aderência de novas tendências caso o comportamento dos usuários mude.

Os resultados apresentados servem de base para as discussões finais do trabalho, apresentadas no capítulo seguinte, no qual são destacadas as contribuições alcançadas e possíveis direções para pesquisas futuras.

CAPÍTULO 4: CONCLUSÃO

4.1. Contribuições

Este trabalho propõe contribuições na área de PLN da língua portuguesa brasileira, não só por utilizar de métodos e ferramentas desenvolvidos para a língua em questão, mas também por se inspirar-se em resultados obtidos em estudos na área, visando manter a comparabilidade entre eles.

Em um nível pessoal, este trabalho demonstrou nitidamente a distinção entre modelos e realidade. Até mesmo as métricas que parecem óbvias e diretas apresentam nuances extremamente relevantes para obter um domínio genuíno do assunto. A análise qualitativa, muitas vezes omitida em artigos, mostrou-se crucial para entender as verdadeiras limitações e peculiaridades do modelo e da base de dados utilizada. Assim, este trabalho forneceu um conhecimento mais amplo do que a simples aplicação de métodos estudados na graduação, sabedoria que somente a experiência fornece. Desta forma, este trabalho foi interessante enquanto introduziu preocupações que fogem de ambientes controlados.

4.2. Relacionamento entre o Curso e o Projeto

Dentre as disciplinas do curso que permitiram o desenvolvimento deste trabalho, as três mais relevantes foram a de Inteligência Artificial, a de Introdução à Ciência de Dados e a de Processamento de Linguagem Natural. Todas ensinaram os métodos e cuidados que tiveram de ser tomados e estimularam a curiosidade na área. Em especial, o tópico do trabalho final ter sido decidido pelos alunos foi decisivo para promover o olhar crítico que este trabalho usou. Outra disciplina que auxiliou o desenvolvimento deste trabalho foi Estatística, especialmente quanto à aplicação de modelos teóricos e distribuições probabilísticas em situações reais.

4.3. Trabalhos Futuros

Partindo dos resultados obtidos deste trabalho, há algumas comparações interessantes que podem ser feitas com escolhas distintas quanto aos métodos aplicados. Primeiramente, o limiar escolhido para definir os valores de referência poderia ser revisto. Como já discutido, muitas resenhas resumiam-se a apenas insultos, elogios e piadas sem elaboração. É possível que escolher um limiar maior possa retirar a maior parte dessas resenhas e criar um modelo mais robusto. Uma análise interessante seria observar como a mudança do valor influencia as métricas de avaliação, como em (BAOWALY et al., 2019) e realizar uma análise qualitativa dos textos classificados.

Outra possível melhoria é escolher que métricas extrair durante o método simbólico, inspirando-se no conjunto de validação. Os pesos poderiam basear-se na intensidade da correlação entre diferentes métricas e a nota final, atentando-se à distribuição possivelmente não linear.

A classificação binária é insuficiente como solução do problema prático postulado. Apesar de sabermos se uma resenha é útil ou não, seria desejável entender o quão útil ela é para situar as melhores em áreas mais acessíveis para informar o consumidor em potencial com maior comodidade. Esta abordagem implicaria em um *ranking* de resenhas, o que, por sua vez, implicaria em uma análise quantitativa baseada em métricas como *Normalized Discounted Cumulative Gain at K (NDCG@K)*, o Coeficiente de Correlação de Postos de Spearman e *Precision@10*.

As *pipelines* dos métodos propostos também poderiam ser aplicados em base de dados de outros domínios além dos jogos. Aplicar os métodos no *UTLcorpus*, por exemplo, permitiria uma comparação entre domínios a fim de entender a generalidade dos métodos.

Como proposto em (LI et al., 2026), um método alternativo que seria de interesse para comparar com estes é o uso de *LLMs* para classificar as resenhas. Este método é particularmente valioso, uma vez que ele pode ser facilmente integrado em um sistema de comentários como o da *Steam* através de uma interface de programação de aplicações (*API*). Outro método cuja comparação poderia render uma discussão relevante é um similar ao proposto em (LI et al., 2025). Este se basearia em criar *embeddings* para metadados e somá-los aos *embeddings* textuais a fim de ter um controle maior de vieses que o texto por

si só não revela. Tais métodos não foram investigados em função do escopo do projeto e do tempo disponível para seu desenvolvimento.

REFERÊNCIAS

BAOWALY, Mrinal; TU, Yi-Pei; CHEN, Kuan-Ta. Predicting the helpfulness of game reviews: a case study on the Steam store. *Journal of Intelligent and Fuzzy Systems*, Amsterdam, v. 36, n. 5, p. 4731-4742, 2019. DOI: 10.3233/JIFS-179022.

BOOS, Rodrigo; PRESTES, Kassius; VILLAVICENCIO, Aline; PADRÓ, Muntsa. brWaC: a WaCky corpus for Brazilian Portuguese. In: BAPTISTA, Jorge et al. (Ed.). *Computational Processing of the Portuguese Language*. Cham: Springer International Publishing, 2014. p. 201-206.

CARVALHO, F. et al. Evaluation of the Brazilian Portuguese version of linguistic inquiry and word count 2015 (BP-LIWC2015). *Language Resources and Evaluation*, v. 58, p. 203–222, 2024. DOI: 10.1007/s10579-023-09647-2.

DEVLIN, Jacob; CHANG, Ming-Wei; LEE, Kenton; TOUTANOVA, Kristina. BERT: pre-training of deep bidirectional transformers for language understanding. In: 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2019, Minneapolis, Minnesota. *Proceedings [...]* Minneapolis: Association for Computational Linguistics, 2019. p. 4171–4186.

ISMAGILOVA, Elvira; SLADE, Emma L.; RANA, Nripendra P.; DWIVEDI, Yogesh K. The effect of electronic word of mouth communications on intention to buy: a meta-analysis. *Information Systems Frontiers*, v. 22, n. 5, p. 1203-1226, 2020. Disponível em: <https://doi.org/10.1007/s10796-019-09924-y>. Acesso em: 2 jun. 2026.

JORGE, Germano A. Z.; PARDO, Thiago A. S.. SteamBR: a dataset for game reviews and evaluation of a state-of-the-art method for helpfulness prediction. In: BRAZILIAN WORKSHOP ON SOCIAL NETWORK ANALYSIS AND MINING (BRASNAM), 12. ,

2023, João Pessoa/PB. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2023. p. 210-215. ISSN 2595-6094. DOI: <https://doi.org/10.5753/brasnam.2023.230132>.

JURAFSKY, Daniel; MARTIN, James H. *Speech and language processing: an introduction to natural language processing, computational linguistics, and speech recognition, with language models*. 3. ed. 2026. Manuscrito online. Disponível em: <https://web.stanford.edu/~jurafsky/slp3/>. Acesso em: 2 jun. 2026.

MANNING, Christopher D.; SCHÜTZE, Hinrich. *Foundations of statistical natural language processing*. Cambridge, MA: MIT Press, 1999.

McLAUGHLIN, G. Harry. SMOG grading: a new readability formula. *Journal of Reading*, v. 12, n. 8, p. 639-646, 1969.

LI, Xinzhe; LI, Qinglong; KIM, Jaekyeong. Instruction-tuned large language models for review helpfulness prediction: an efficient fine-tuning framework for e-commerce review understanding. *Expert Systems*, v. 43, n. 3, e70208, 2026. DOI: <https://doi.org/10.1111/exsy.70208>.

LI, Xinzhe; LI, Qinglong; RYU, Dongyeop; KIM, Jaekyeong. A BERT-based review helpfulness prediction model utilizing consistency of ratings and texts. *Applied Intelligence*, v. 55, art. 455, 2025. DOI: 10.1007/s10489-024-06100-x.

SARDINHA, Tony Berber. Linguística de corpus: histórico e problemática. *DELTA: Documentação de Estudos em Linguística Teórica e Aplicada*, São Paulo, v. 16, n. 2, p. 323–367, 2000. DOI: 10.1590/S0102-44502000000200005. Disponível em: <https://doi.org/10.1590/S0102-44502000000200005>. Acesso em: 4 jun. 2026.

SOUSA, Rogério Figueredo; BRUM, Henrico Bertini; NUNES, Maria das Graças Volpe. A bunch of helpfulness and sentiment corpora in Brazilian Portuguese. In: Symposium in Information and Human Language Technology, 2019. *Proceedings...* Porto Alegre: Sociedade Brasileira de Computação, 2019.

SOUSA, Rogério Figueredo de; PARDO, Thiago Alexandre Salgueiro. The Challenges of Modeling and Predicting Online Review Helpfulness. In: ENCONTRO NACIONAL DE INTELIGÊNCIA ARTIFICIAL E COMPUTACIONAL (ENIAC), 18. , 2021, Evento Online. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2021 . p. 727-738. ISSN 2763-9061. DOI: <https://doi.org/10.5753/eniac.2021.18298>.

SOUZA, Fábio; NOGUEIRA, Rodrigo; LOTUFO, Roberto. BERTimbau: pretrained BERT models for Brazilian Portuguese. In: Brazilian Conference on Intelligent Systems, 9., 2020, Rio Grande, RS. *Intelligent Systems*. Cham: Springer International Publishing, 2020. p. 403-417. DOI: 10.1007/978-3-030-61377-8_28.

VASWANI, Ashish et al. Attention Is All You Need. In: Advances in Neural Information Processing Systems 30. Long Beach, 2017. p. 5998–6008.

ZHAO, Wayne Xin et al. A Survey of Large Language Models. arXiv, 2023. DOI: 10.48550/arXiv.2303.18223. Disponível em: <https://arxiv.org/abs/2303.18223>. Acesso em: 2 jul. 2026.